


Fundamentos de NLP e Análise de Corpora




**Tarefa 01: Definições e
Aplicações Práticas (NLTK)**

Processamento de Linguagem Natural

Aluno: André Salerno
(RA: 1461392411015)
Professor: Fabrício Galende
Marques de Carvalho

A Hierarquia Estrutural do Texto



Relação hierárquica base: **palavra** $\subset$ **frase** $\subset$ **documento** $\subset$ **corpus** $\subset$ **corpora**

Aplicações no Mundo Real: Domínios Transacionais

E-commerce (Amazon / Mercado Livre)



Frase: “O produto chegou dois dias antes do prazo...”

Documento: Avaliação completa (Nota, título, texto, data, “compra verificada”).

Corpus: 80 mil avaliações da categoria Fones de Ouvido (2023).

Corpora: Amazon (Fones) U Mercado Livre (Fones).

Helpdesk de TI




Frase: “Não consigo acessar minha conta corporativa...”

Documento: Ticket completo (Assunto, descrição, histórico, prioridade).


Corpus: Todos os tickets de TI abertos em 2024.

Corpora: Tickets de TI U Tickets de RH.


Aplicações no Mundo Real: Literatura e Conhecimento



Aplicações no Mundo Real: Fluxos Conversacionais



Transição para a Prática: O Ambiente NLTK



Spec Sheet 01: Machado (Texto Puro)

Origem: Obra Completa de Machado de Assis (Domínio Público, MEC).

Período: 1854–1939.

Volume: 246 arquivos .txt / 3.121.944 palavras.

Anotação: Nenhuma (Plaintext).

Codificação: ISO-8859-1 (latin-1).

machado/

- | — romance/ (10 arquivos, ex: Dom Casmurro)
- | — contos/ (137 arquivos)
- | — cronica/
- | — poesia/
- | — teatro/ ...

[OUTPUT RAW]: Romance, Dom Casmurro, 1899. Publicado originalmente pela Editora Garnier...

Spec Sheet 02: Mac-Morpho (Anotação POS)

Origem: Jornal Folha de S.Paulo (Projeto Lácio-Web / NILC).

Período: 1994.

Volume: 109 arquivos / ~1,17 M palavras / 51.397 frases.

Anotação: Morfossintática (POS Tagging) - 82 etiquetas distintas.

Transformação Lexical

[Jersey] → N

[atinge] → V

[média] → N

[de] → PREP

[Cr\$] → CUR


Spec Sheet 03: Floresta Sintáctica (Treebank)

Origem: Jornais Público (PT) e Folha de S.Paulo (BR) via LINGUECA.

Período: Final dos anos 1990.


Volume: 1 arquivo (.ptb) / ~212 mil palavras / 9.266 frases.

Anotação: Sintática em constituintes (função + categoria) - 269 etiquetas.



(As etiquetas combinam função sintática e categoria morfológica no mesmo nó).

O Espectro da Anotação Linguística



Matriz Comparativa Definitiva

	Machado	Mac-Morpho	Floresta Sintáctica
Tipo/Fonte	Literário (Nova Aguilar)	Jornalístico (Folha)	Jornalístico (Público + Folha)
Variedade	PT-BR	PT-BR	PT-PT + PT-BR
Época	1854–1939	1994	Anos 1990
Tamanho	~246 obras	~1,17 M palavras	~212 k palavras
Anotação	Nenhuma (Plaintext)	POS (Morfossintática)	Sintática (Constituintes)
NLTK Reader	CategorizedPlaintext	MacMorpho / Tagged	BracketParse
Método-chave	.categories()	.tagged_words()	.parsed_sents()

Implicações para Modelagem em NLP



Machado

- **Uso Ideal:** Estudos de estilo (Estilometria) e análise computacional de autoria.

- **Uso Ideal:** Modelagem de linguagem histórica do português brasileiro.



Mac-Morpho

- **Uso Ideal:** Treino, validação e avaliação de POS taggers para o português.

- **Uso Ideal:** Estudos quantitativos de frequência de classes gramaticais no jornalismo.



Floresta Sintáctica

- **Uso Ideal:** Treino e avaliação de parsers e chunkers.

- **Uso Ideal:** Extração automática de gramáticas e estudos profundos de sintaxe luso-brasileira.

Referências Bibliográficas

CARVALHO, Fabrício Galende Marques de. Introdução ao Processamento de Linguagem Natural.

NLTK Documentation — Accessing Text Corpora and Lexical Resources (nltk.org).

Portal Machado de Assis — Obra Completa (machado.mec.gov.br).

NILC / Projeto Lácio-Web (nilc.icmc.usp.br/lacioweb/).

Projecto Floresta Sintáctica / Linateca (linguateca.pt/Floresta/).

Repositório Base: github.com/fabriciogmc/natural_language_processing